7.4 实践中使用式(7.15)决定分类类别时, 若数据的维数非常高, 则概率连乘 $\prod_{i=1}^d P(x_i \mid c)$ 的结果通常会非常接近于 0 从而导致下溢. 试述防止下溢的可能方案.

$$h_{nb}(\boldsymbol{x}) = \underset{c \in \mathcal{Y}}{\operatorname{arg\,max}} \ P(c) \prod_{i=1}^{d} P(x_i \mid c) \ , \tag{7.15}$$

为防山下溢,可对上式取对数,将连乘变改连加。

$$P h_{nb}(x) = arg \max_{c \in \mathcal{Y}} log P(c) + \sum_{i=1}^{d} log (P(x_i|c))$$

茗结果出现一一溢出, 引以在每次取对数可除以名函数,

$$RP \quad h_{Nb}(x) = \underset{c \in \mathcal{Y}}{arg \; max} \quad \frac{\log P(c)}{d+1} + \underset{i=1}{\overset{d}{\underset{}}} \quad \frac{\log (P(xi|c))}{d+1}$$

7.5 试证明:二分类任务中两类数据满足高斯分布且方差相同时,线性判 ^{假设同先验;参见 3.4} 别分析产生贝叶斯最优分类器.

由只叶斯呈現,
$$P(c|\pi) = \frac{P(c|\pi)}{P(\pi)} = \frac{P(c)P(\pi|c)}{P(\pi)}$$

若数据服从高斯分布,则有 $P(n|c) \sim N(Hc, \Sigma_c)$, μ 为均值向量, Σ_c 为结辩阵.

$$h^*(\pi) = \arg\max_{c \in \mathcal{Y}} P(c|\pi) <=> \arg\max_{c \in \mathcal{Y}} P(\pi|c) P(c) <=> \arg\max_{c \in \mathcal{Y}} \log (f(\pi|c) P(c))$$

$$= \arg\max_{c \in \mathcal{Y}} \log \frac{1}{\int (2\pi)^d |\Sigma_c|} e^{-\frac{1}{2}(\pi - \mu_c)} + \log (P(c))$$

$$= \arg\max_{c \in \mathcal{Y}} -\frac{1}{2}(\pi - \mu_c)^T \Sigma_c^{-1}(\pi - \mu_c) + \log(P(c))$$

$$= \arg\max_{c \in \mathcal{Y}} -\frac{1}{2}(\pi^T \Sigma_c^{-1}(\pi - \mu_c)) + \log(P(c))$$

= arg max - = (xTz=1x -2xTz=1/2) + log(P(e))

对于二分类任务,没类例 1 数据的词值白量为 /L,类例 0 数据的均值白量为 /Lo,两类数据满足高斯分布且方差 Z 相同.

• 证明EM算法的收敛性

设 P(×1θ)为欢测 数据的似型函数,Θ⁽¹⁾(i=1,2,…)为EM算法得到的参数估计序列, 设 L(θ) = 10g P(×1θ), L(Θ⁽¹⁾)(i=1,2,…)为对应的 对影似包旦农序列。

下诏 L(0(1)) 星草阁基谊的, 即 log P(×10(11)) > log P(×10(11)).

$$b(x|0) = \frac{b(z|x,0)}{b(x,5|0)}$$

取对数有 log P(X18) = log (X,218) - log (21X,8)

 $Q(\theta, \theta^{(i)}) = \sum_{z} \log P(x, z | \theta) P(z | x, \theta^{(i)})$

A H(0,00) = 5 log P(2 | x, 0) P(2 | x, 00)

于是对数似型函数可以写成 $\log P(x|\theta) = Q(\theta, \theta^{(i)}) - H(\theta, \theta^{(i)})$

10g P(X | 0000) - 10g P(X | 000) = [Q(000,000) - Q(000,000)] - [H(0000,000) - H(000,000)]

· O(im) 健 Q(8,0(i)) 达极大 · Q(0(im),0(i)) - Q(0(i),0(i)) >0

$$H(0^{(it)},0^{(i)}) - H(0^{(i)},0^{(i)}) = \frac{1}{2} \left(\log \frac{P(2|x,0^{(it)})}{P(3|x,0^{(i)})} \right) P(2|x,0^{(i)})$$

$$\leq \log \left(\frac{1}{2} \frac{P(2|x,0^{(it)})}{P(3|x,0^{(i)})} \right) P(2|x,0^{(i)})$$

$$= \log P(2|x,0^{(it)}) = 0$$

: 10g P(x|0(171)) - 10g P(x10") 30

P(X10)有界,L(0)单调,则 L(0111)收敛剂某-值 L*. EM算该的收敛性得证.

• 在HMM中,求解概率 $P(x_{n+1}|x_1, x_2, \ldots, x_n)$

$$P(x_{n+1} | x_1, x_2, \dots, x_n) = \frac{P(x_1, x_2, \dots, x_n, x_{n+1})}{P(x_1, x_2, \dots, x_n)}$$

$$= \frac{P(y_1) P(x_1 | y_1) \prod_{i=2}^{n+1} P(y_k | y_{k-1}) P(x_k | y_k)}{P(y_1) P(x_1 | y_1) \prod_{i=2}^{n} P(y_k | y_{k-1}) P(x_k | y_k)}$$

$$= P(y_{n+1} | y_n) P(x_{n+1} | y_{n+1})$$

- 2. 假设数据集 $D = \{x_1, x_2, ..., x_m\}$,任意 x_i 是从均值为 μ 、方差为 λ^{-1} 的正态分布 $\mathcal{N}(\mu, \lambda^{-1})$ 中独立采样而得到。假设 μ 和 λ 的先验分布为 $p(\mu, \lambda) = \mathcal{N}(\mu|\mu_0, (\kappa_0\lambda)^{-1})$ Gam $(\lambda|a_0, b_0)$ 其 中 Gam $(\lambda|a_0, b_0) = \frac{1}{\Gamma(a_0)}b_0^{a_0}\lambda^{a_0-1}\exp\left(-b_0\lambda\right)$
- (1) 请写出联合概率分布p(D, μ, λ)
- (2) 请写出证据下界(即变分推断的优化目标),并证明其为观测数据边际似然 $\sum_{i=1}^{m} \log p(x_i)$ 的下界
- (3) 请用变分推断法近似推断后验概率 $p(\mu, \lambda | D)$

(1)
$$p(D, \mu, \lambda) = p(D|\mu, \lambda) p(\mu, \lambda)$$

$$= p(\mu, \lambda) \prod_{i=1}^{m} p(\pi_i | \mu, \lambda)$$

$$= \frac{1}{\sqrt{2\pi (k_0 \lambda)^{-1}}} \exp\left(-\frac{1}{2(k_0 \lambda)^{-1}} (\mu - \mu_0 x)\right) \frac{1}{\Gamma(a_0)} b^{a_0} \lambda^{a_0 - 1} \exp(-b_0 \lambda) \left(\frac{\lambda}{2\pi}\right)^{\frac{m}{2}} \exp\left(-\frac{\lambda}{2\pi} \sum_{i=1}^{m} (\pi_i - \mu_i^2)\right)$$

[2] 记据下界: E [|og p(=1 xx)] - E [|og q(zx)]

故证据下界也为 Log P(xi) 的下界。

(b) k = (q||P) = -L + |nP| , 可通过最大化 L 使得 k = 1 散废最小 $\frac{\partial L}{\partial Q(\mu)} = E_{\lambda} [\log P(\mu|\lambda)] + E_{\lambda} [\log P(D|\mu\lambda)] - \log Q(\mu) = 0$

$$|09| 9* (H) = -\frac{Ey}{5} [(k_0 + m)(H - \frac{Fy}{5} \frac{m}{5} x_1^2 - 2H(k_0 H_0 + mx)]$$

$$= -\frac{Fy}{5} [(k_0 + m)(H - \frac{Fy}{5} \frac{m}{5} x_1^2 - 2H(k_0 H_0 + mx)]$$

$$= -\frac{Fy}{5} [(k_0 + m)(H - \frac{Fy}{5} \frac{m}{5} x_1^2 - \frac{(k_0 H_0 + mx)^2}{F_0 + m})]$$

 $\frac{\partial L}{\partial g_{\mu}(\lambda)} = E_{\mu} \left[\log P(D|\lambda, \mu) + E \left[\log (\mu|\lambda) \right] + E_{\mu} \left[\log P(\lambda) \right] - \log q(\lambda) = 0$

 $\log q^*(\lambda) = -\frac{\lambda}{2} \, \mathbb{E}_{\mu} \, \mathbb{E}_{k} \, (\mu - \mu \circ)^2 + \frac{m}{2} \, (\pi_1 - \mu)^2 \, \mathbb{I} + (\pi_0 - 1) \, \log \lambda - \log \lambda + \frac{m+1}{2} \, \log \lambda$ $= (\alpha_0 + \frac{m-1}{2}) \, \log \lambda - (\beta_0 + \frac{1}{2} \, \mathbb{E}_{\mu} \, \mathbb{E}_{k} \, (\mu - \mu \circ)^2 + \frac{m}{2} \, (\pi_1 - \mu)^2 \, \mathbb{I}) \, \lambda$

i q*(x) ~ Gam (x | am, bm) ,其中 am = ao + m+1 , bm = bo + 1 Eμ [+o (μ-μο)² + (x; -μ)²]

:独立 : (*(ドハ) = (*(ル) (* ハ) ~ N (μ | μm , xm) Gam (x | am, bm)

无发验时,有 po = ao = bo = ko = 0

节回入m、bm得入, b', 则 P(从,>10) ~ N(从1 //m,入') Gam (x | am, b')

3. PPT 46, 给出CRF的预测问题的解法

在条件随机场预测问题中,CRF预测问题就成为3求非规范化概算最大的最优强征问题。 使用 Viter bi 算法:

输入:模型特征向量下(Y,x),权值向量 ω , 观测序列 $x=(x_1,x_2,\cdots,x_n)$ 输出: 最优路径 $y^*=(y^*,y^*_2,\cdots,y^*_n)$.

1. 初始化位置 1 的各个标记 j = 1,2,···,m 的非规范化概率.

2. 对 i=2,3,…,n 递推计算.

$$\begin{split} & S_{i}(L) = \max_{1 \leq j \leq m} \left\{ S_{i-1}(j) + w \cdot F_{i}(y_{i-1} = j, y_{i} = L, x) \right\}, \quad l = 1, 2, \cdots, m \\ & \psi_{i}(L) = \arg\max_{1 \leq j \leq m} \left\{ S_{i-1}(j) + w \cdot F_{i}(y_{i-1} = j, y_{i} = L, x) \right\}, \quad l = 1, 2, \cdots, m \end{split}$$

3. 终止

$$max (w \cdot F(y,x)) = max Sn(j)$$
 y
 $sign = arg max Sn(j)$
 $sign = arg max Sn(j)$

4. 返回路径

$$y_i^* = Y_{i+1}(y_{i+1}^*)$$
, $i = n-1, n-2, \dots, 1$

4 保存每个节点的最大非规范化概率的前导节点,即当前节点的最优前节点,最优路径发飞和最优经稳定, 然后根据最优经稳定从4里面书出他的最优前前节点,依次形出 Yn, Yn, ..., Yn.

则 y* = (y*, y2*, ···, y*n) 就是杂件随机场交测问题的最份路径.