



2022年秋季 《机器学习概论》课程

第十四章：概率图模型

主讲：连德富 特任教授 | 博士生导师

邮箱：liandefu@ustc.edu.cn

手机：13739227137

主页：<http://staff.ustc.edu.cn/~liandefu>

概率模型

- 机器学习最重要的任务是根据**已观察**到的证据（例如训练样本）对感兴趣的**未知**变量（例如类别标记）进行估计和推测。
- **概率模型**（probabilistic model）提供了一种描述框架，将描述任务归结为**计算变量的概率分布**，在概率模型中，利用**已知**的变量推测**未知**变量的分布称为“推断（inference）”，其**核心**在于基于可观测的变量推测出未知变量的**条件分布**
 - 生成式：计算联合分布 $P(Y, R, O)$
 - 判别式：计算条件分布 $P(Y, R|O)$
- 符号约定
 - Y 为关心的变量的集合， O 为可观测变量集合， R 为其他变量集合



概率模型

直接利用概率求和规则消去变量R的时间和空间复杂度为**指数级别** $O(2^{|Y|+|R|})$ ，需要一种能够简洁紧凑**表达变量间关系**的工具


概率图模型

概率图模型


- 概率图模型(probabilistic graphical model)是一类用图来表达**变量相关关系**的概率模型
- 图模型提供了一种**描述框架**,
 - 结点: 随机变量 (集合)
 - 边: 变量之间的依赖关系
- 分类:
 - **有向图**: 贝叶斯网
 - 使用有向无环图表示变量之间的依赖关系
 - **无向图**: 马尔可夫网
 - 使用无向图表示变量间的相关关系

概率图模型

- 概率图模型分类：
 - 有向图：贝叶斯网
 - 无向图：马尔可夫网



有向图



无向图

本章概要

- 隐马尔可夫模型（动态贝叶斯网）
- 马尔可夫随机场 / 条件随机场
- 主题模型

隐马尔可夫模型

- 隐马尔可夫模型 (Hidden Markov Model, HMM)


- 组成

- 状态变量: $\{y_1, y_2, \dots, y_n\}$ 通常假定是**隐藏的**, 不可被观测的

- 取值范围为 y , 通常有 N 个可能取值的离散空间

- 观测变量: $\{x_1, x_2, \dots, x_n\}$ 表示第 i 时刻的观测值集合

- 观测变量可以为离散或连续型, 本章中只讨论离散型观测变量, 取值范围 x 为 $\{o_1, o_2, \dots, o_M\}$




隐马尔可夫模型

- t 时刻的状态 x_t 仅依赖于 $t - 1$ 时刻状态 x_{t-1} , 与其余 $n - 2$ 个状态无关

马尔可夫链:

系统下一时刻状态仅由当前状态决定, 不依赖于以往的任何状态

$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1|y_1) \prod_{t=2}^n P(y_t|y_{t-1})P(x_t|y_t)$$




联合概率

马尔可夫随机场

- 马尔可夫随机场 (Markov Random Field, MRF)

- 是典型的马尔可夫网
- 著名的**无向图**模型




- 图模型表示:

- 结点表示变量 (集), 边表示依赖关系
- 有一组势函数 (Potential Functions), 亦称 “因子” (factor), 这是定义在变量子集上的非负实函数, 主要用于定义概率分布函数

马尔可夫随机场—分布形式化:

- 使用基于**极大团**的势函数 (因子)
 - 对于图中结点的一个子集, 若其中任意两结点间都有边连接, 则称该结点子集为一个“团” (clique)。若一个团中加入另外任何一个结点都不再形成团, 则称该团为“极大团” (maximal clique)
 - 图中 $\{x_1, x_2\}$, $\{x_2, x_6\}$, $\{x_2, x_5, x_6\}$ 等为团
 - 图中 $\{x_2, x_6\}$ 不是极大团
 - 每个结点至少出现在一个极大团中



马尔可夫随机场

- 使用基于**极大团**的势函数（因子）
 - 对于 n 个变量 $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$, 所有团构成的集合为 \mathcal{C} , 与团 $Q \in \mathcal{C}$ 对应的变量集合记为 \mathbf{x}_Q , 则联合概率定义为:

$$P(\mathbf{x}) = \frac{1}{Z} \prod_{Q \in \mathcal{C}} \psi_Q(\mathbf{x}_Q)$$

- 其中, ψ_Q 是于团 Q 对应的势函数, Z 为概率的规范化因子
- 在实际应用中, Z 往往很难精确计算。但很多任务中, 不需要对 Z 进行精确计算
- 若变量问题较多, 则团的数目过多, 上式的乘积项过多, 会给计算带来负担, 所以需要考虑极大团

马尔可夫随机场

- 联合概率分布可以使用极大团定义，假设所有极大团构成的集合为 \mathcal{C}^*

$$P(\mathbf{x}) = \frac{1}{Z^*} \prod_{Q \in \mathcal{C}^*} \psi_Q(\mathbf{x}_Q)$$


- 其中， Z^* 是规范化因子 $Z^* = \sum_{\mathbf{x}} \prod_{Q \in \mathcal{C}^*} \psi_Q(\mathbf{x}_Q)$

马尔可夫随机场

- 使用基于**极大团**的势函数（因子）
 - 联合概率分布可以使用极大团定义，假设所有极大团构成的集合为 \mathcal{C}^*

$$P(\mathbf{x}) = \frac{1}{Z^*} \prod_{Q \in \mathcal{C}^*} \psi_Q(\mathbf{x}_Q)$$

- 图模型




- 联合概率分布

$$P(\mathbf{x}) = \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6)$$


马尔可夫随机场中的分离集

- 马尔可夫随机场中得到 “**条件独立性**”
- 借助 “**分离**” 的概念，若从结点集A中的结点到B中的结点都必须经过结点集C中的结点，则称结点集A，B被结点集C分离，称C为分离集 (separating set)




全局马尔可夫性

- 借助“分离”的概念，可以得到：
 - **全局马尔可夫性** (global Markov property)：在给定**分离集**的条件下，两个变量子集条件独立
 - 若令A,B,C对应的变量集分别为 x_A , x_B , x_C ，则 x_A 和 x_B 在 x_C 给定的条件下独立，记为 $x_A \perp x_B \mid x_C$



全局马尔可夫性的验证

- 图模型简化:



- 得到图模型的联合概率为: $P(x_A, x_B, x_C) = \frac{1}{Z} \psi_{AC}(x_A, x_C) \psi_{BC}(x_B, x_C)$

条件概率

$$\begin{aligned}
 P(x_A, x_B | x_C) &= \frac{P(x_A, x_B, x_C)}{\sum_{x_A, x_B} P(x_A, x_B, x_C)} \\
 &= \frac{\frac{1}{Z} \psi_{AC}(x_A, x_C) \psi_{BC}(x_B, x_C)}{\sum_{x_A, x_B} \frac{1}{Z} \psi_{AC}(x_A, x_C) \psi_{BC}(x_B, x_C)} \\
 &= \frac{\psi_{AC}(x_A, x_C)}{\sum_{x_A} \psi_{AC}(x_A, x_C)} \frac{\psi_{BC}(x_B, x_C)}{\sum_{x_B} \psi_{BC}(x_B, x_C)} \\
 &= P(x_A | x_C) P(x_B | x_C)
 \end{aligned}$$

$$\begin{aligned}
 P(x_A | x_C) &= \frac{\sum_{x_B} P(x_A, x_B, x_C)}{\sum_{x_A, x_B} P(x_A, x_B, x_C)} \\
 &= \frac{\sum_{x_B} \frac{1}{Z} \psi_{AC}(x_A, x_C) \psi_{BC}(x_B, x_C)}{\sum_{x_A, x_B} \frac{1}{Z} \psi_{AC}(x_A, x_C) \psi_{BC}(x_B, x_C)} \\
 &= \frac{\psi_{AC}(x_A, x_C)}{\sum_{x_A} \psi_{AC}(x_A, x_C)}
 \end{aligned}$$

马尔可夫随机场中的条件独立性


全局马尔可夫性 (global Markov property) : 在给定**分离集**的条件下, 两个变量子集条件独立

- **局部马尔可夫性** (local Markov property) : 在给定**邻接变量**的情况下, 一个变量条件独立于其它所有变量

- 令 V 为图的结点集, $n(v)$ 为结点 v 在图上的邻接节点, $n^*(v) = n(v) \cup \{v\}$, 有 $x_v \perp x_{V \setminus n^*(v)} \mid x_{n(v)}$


- **成对马尔可夫性** (pairwise Markov property) : 在给定**所有其它变量**的情况下, 两个非邻接变量条件独立

- 令 V 为图的结点集, 边集为 E , 对图中的两个结点 u, v , 若 $\langle u, v \rangle \notin E$, 有 $x_u \perp x_v \mid x_{V \setminus \{u, v\}}$



马尔可夫随机场中的势函数

- 势函数 $\psi_Q(x_Q)$ 的作用是定量刻画变量集 x_Q 中变量的相关关系, 应为非负函数, 且在所偏好的变量取值上有较大的函数值



- 上图中, 假定变量均为二值变量, 定义势函数:

$$\psi_{AC}(x_A, x_C) = \begin{cases} 1.5, & \text{if } x_A = x_C \\ 0.1, & \text{otherwise} \end{cases}$$

$$\psi_{BC}(x_B, x_C) = \begin{cases} 0.2, & \text{if } x_B = x_C \\ 1.3, & \text{otherwise} \end{cases}$$

模型偏好 x_A 与 x_C 有相同的取值
 x_A 与 x_C 正相关

模型偏好 x_B 与 x_C 有不同的取值
 x_B 与 x_C 负相关

令 x_A 与 x_C 相同且 x_B 与 x_C 不同的变量值指派将有较高的联合概率

马尔可夫随机场中的势函数

- 势函数 $\psi_Q(x_Q)$ 的作用是定量刻画变量集 x_Q 中变量的相关关系，应为非负函数，且在所偏好的变量取值上有较大的函数值
- 为了满足**非负性**，指数函数常被用于定义势函数，即：

$$\psi_Q(x_Q) = e^{-H_Q(x_Q)}$$


- 其中， $H_Q(x_Q)$ 是一个定义在变量 x_Q 上的实值函数，常见形式为：

$$H_Q(x_Q) = \sum_{u,v \in Q, u \neq v} \alpha_{uv} x_u x_v + \sum_{v \in Q} \beta_v x_v$$


- 其中， α_{uv} 和 β_v 是参数，上式第一项考虑每一对结点的关系，第二项考虑单结点

条件随机场

- 条件随机场 (Conditional Random Field, CRF) 是一种**判别式**无向图模型 (可看作给定观测值的MRF)，条件随机场对多个变量给定相应**观测值**后的条件概率进行建模
- 若令 $\mathbf{x} = \{x_1, x_2, \dots, x_n\}$ 为观测序列， $\mathbf{y} = \{y_1, y_2, \dots, y_n\}$ 为对应的标记序列，CRF的目标是构建条件概率模型 $P(\mathbf{y}|\mathbf{x})$
- 标记变量 \mathbf{y} 可以是结构型变量，它各个分量之间具有某种相关性。
 - 自然语言处理的词性标注任务中，观测数据为语句 (单词序列)，标记为相应的词性序列，具有线性序列结构
 - 在语法分析任务中，输出标记是语法树，具有树形结构



(a) 词性标注



(b) 语法分析


条件随机场

- 令 $G = \langle V, E \rangle$ 表示结点与标记变量 y 中元素一一对应的无向图。无向图中, Y_v 表示与节点 v 对应的标记变量, $n(v)$ 表示结点 v 的邻接结点, 若图中的每个结点都满足马尔可夫性,

$$P(Y_v | X, Y_{V \setminus \{v\}}) = P(Y_v | X, Y_{n(v)})$$


则 (Y, X) 构成条件随机场

- CRF 使用势函数和图结构上的团来定义 $P(y|x)$
- 接下来仅考虑**链式**条件随机场 (chain-structured CRF)



链式条件随机场

- 包含两种关于标记变量的团：
 - 相邻的标记变量，即 $\{y_{i-1}, y_i\}$;
 - 单个标记变量， $\{y_i\}$;
- 条件概率可被定义为：



$$P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{j=1}^{K_1} \sum_{i=2}^n \lambda_j t_j(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{l=1}^{K_2} \sum_{i=1}^n \mu_l s_l(y_i, \mathbf{x}, i) \right)$$

- $t_j(y_{i+1}, y_i, \mathbf{x}, i)$ 是定义在观测序列的两个相邻标记位置上的转移特征函数 (transition feature function) , 用于刻画相邻标记变量之间的相关关系以及观测序列对它们的影响
- $s_k(y_i, \mathbf{x}, i)$ 是定义在观测序列的标记位置*i*上的状态特征函数 (status feature function) , 用于刻画观测序列对标记变量的影响
- λ_j, μ_k 为参数, Z 为规范化因子

CRF特征函数举例

- **特征函数**通常是实值函数，以刻画数据的一些**很可能成立**或者**期望成立**的经验特性，以词性标注任务为例：


$$\begin{array}{l} \mathbf{y} \quad \{y_1 \quad y_2 \quad y_3 \quad y_4 \quad y_5 \quad y_6\} \\ \quad \boxed{[D] \quad [N] \quad [V] \quad [P] \quad [D] \quad [N]} \\ \\ \mathbf{x} \quad \{x_1 \quad x_2 \quad x_3 \quad x_4 \quad x_5 \quad x_6\} \\ \quad \boxed{\text{The boy knocked at the watermelon.}} \end{array}$$

- 采用特征函数：

$$t_j(y_{i+1}, y_i, \mathbf{x}, i) = \begin{cases} 1, & \text{if } y_{i+1} = [P], y_i = [V], \text{ and } x_i = \text{"knock"} \\ 0, & \text{otherwise} \end{cases}$$

- 表示第 i 个观测值 x_i 为单词'knock'时，相应的标记 y_i, y_{i+1} 很可能分别为 $[V], [P]$.


HMM to CRF



$$\begin{aligned}
 P(\mathbf{x}, \mathbf{y}) &= P(y_1)P(x_1|y_1) \prod_{t=2}^n P(y_t|y_{t-1})P(x_t|y_t) \\
 &= \pi_{y_1} b_{y_1, x_1} a_{y_1, y_2} b_{y_2, x_2} a_{y_2, y_3} \cdots a_{y_{n-1}, y_n} b_{y_n, x_n} \\
 &= \exp \left(\sum_{t=1}^{n-1} \sum_{i,j} \mathbb{I}(y_t = s_i, y_{t+1} = s_j) \log a_{ij} + \sum_i \mathbb{I}(y_1 = s_i) \log \pi_i \right. \\
 &\quad \left. + \sum_{t=1}^n \sum_{j,k} \mathbb{I}(y_t = s_j, x_t = o_k) \log b_{jk} \right)
 \end{aligned}$$


MRF与CRF的对比

- 使用团上的势函数定义概率
- 对**联合概率**建模



$$P(\mathbf{x}) = \frac{1}{Z} \psi_{12}(x_1, x_2) \psi_{13}(x_1, x_3) \psi_{24}(x_2, x_4) \\ \psi_{35}(x_3, x_5) \psi_{256}(x_2, x_5, x_6)$$

- 使用团上的势函数定义概率
- 有观测变量，对**条件概率**建模



$$P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{j=1}^{K_1} \sum_{i=2}^n \lambda_j t_j(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{l=1}^{K_2} \sum_{i=1}^n \mu_l s_l(y_i, \mathbf{x}, i) \right)$$

CRF基本问题

- **概率计算问题**: 评估模型和观测序列间的匹配程度:
有效计算观测序列产生概率 $P(x|\lambda)$
- **预测问题**: 根据观测序列 “推测” 隐藏的模式状态
 $y = \{y_1, y_2, \dots, y_n\}$
- **学习问题**: 如何调整模型参数 $\lambda = [A, B, \pi]$ 以使得
该序列出现的概率 $P(x|\lambda)$ 最大

概率计算问题

$$P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{j=1}^{K_1} \sum_{i=2}^n \lambda_j t_j(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{l=1}^{K_2} \sum_{i=1}^n \mu_l s_l(y_i, \mathbf{x}, i) \right)$$

假设 $y_0 = \text{"start"}$ 且 $y_{n+1} = \text{"end"}$

$$\text{记 } f_k(y_{i-1}, y_i, \mathbf{x}, i) = \begin{cases} t_k(y_{i-1}, y_i, \mathbf{x}, i), & k = 1, \dots, K_1 \\ s_l(y_i, \mathbf{x}, i), & l = K_1 + l; l = 1, \dots, K_2 \end{cases}$$

定义 $M_i(\mathbf{x}) = [M_i(y_{i-1}, y_i | \mathbf{x})] \rightarrow \exp(W_i(y_{i-1}, y_i | \mathbf{x})) \rightarrow \sum_{k=1}^{K_1+K_2} w_k f_k(y_{i-1}, y_i, \mathbf{x}, i)$

$$P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x}) \quad Z = \sum_{\mathbf{y}_1, \dots, \mathbf{y}_n} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x})$$

概率计算问题

$$Z = \sum_{y_1, \dots, y_n} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x}) = \alpha_{n+1}(y_{n+1} | \mathbf{x}) = [M_1(\mathbf{x}) M_2(\mathbf{x}) \cdots M_{n+1}(\mathbf{x})]_{start, stop}$$

$$= \sum_{y_1} M_1(y_0, y_1 | \mathbf{x}) \underbrace{\sum_{y_2} M_2(y_1, y_2 | \mathbf{x}) \sum_{y_3} M_3(y_2, y_3 | \mathbf{x}) \cdots \sum_{y_n} M_n(y_{n-1}, y_n | \mathbf{x}) M_{n+1}(y_n, y_{n+1} | \mathbf{x})}_{\text{前t项求和}}$$

$$\alpha_{t+1}(y_{t+1} | \mathbf{x}) = \sum_{y_1, \dots, y_t} \prod_{i=1}^{t+1} M_i(y_{i-1}, y_i | \mathbf{x})$$

$$= \sum_{y_t} M_{t+1}(y_t, y_{t+1} | \mathbf{x}) \left(\sum_{y_1, \dots, y_{t-1}} \prod_{i=1}^t M_i(y_{i-1}, y_i | \mathbf{x}) \right)$$

$$= \sum_{y_t} M_{t+1}(y_t, y_{t+1} | \mathbf{x}) \alpha_t(y_t | \mathbf{x}) \quad \text{记 } \alpha_0(y_0 | \mathbf{x}) = \begin{cases} 1, & y_0 = start \\ 0, & otherwise \end{cases}$$

$$\Rightarrow \alpha_{t+1}(\mathbf{x}) = \alpha_t(\mathbf{x}) M_{t+1}(\mathbf{x}) \Rightarrow \alpha_{n+1} = \alpha_0(\mathbf{x}) M_1(\mathbf{x}) M_2(\mathbf{x}) \cdots M_{n+1}(\mathbf{x})$$

概率计算问题

$$\begin{aligned}\beta_t(y_t|\mathbf{x}) &= \sum_{y_{t+1}, \dots, y_n} \prod_{i=t+1}^{n+1} M_i(y_{i-1}, y_i|\mathbf{x}) \\ &= \sum_{y_{t+1}} M_{t+1}(y_t, y_{t+1}|\mathbf{x}) \left(\sum_{y_{t+2}, \dots, y_{n+1}} \prod_{i=t+2}^{n+1} M_i(y_{i-1}, y_i|\mathbf{x}) \right) \\ &= \sum_{y_{t+1}} M_{t+1}(y_t, y_{t+1}|\mathbf{x}) \beta_{t+1}(y_{t+1}|\mathbf{x})\end{aligned}$$

$$\Rightarrow \beta_t(\mathbf{x}) = M_{t+1}(\mathbf{x}) \beta_{t+1}(\mathbf{x}) \quad \Rightarrow \beta_t(\mathbf{x}) = M_{t+1}(\mathbf{x}) \cdots M_{n+1}(\mathbf{x}) \beta_{n+1}(\mathbf{x})$$

$$\text{记 } \beta_{n+1}(y_{n+1}|\mathbf{x}) = \begin{cases} 1, & y_{n+1} = \text{end} \\ 0, & \text{otherwise} \end{cases}$$

概率计算问题

$$\begin{aligned}P(y_t|\mathbf{x}) &= \sum_{\mathbf{y}_{-t}} P(\mathbf{y}|\mathbf{x}) = \sum_{\mathbf{y}_{-t}} \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i|\mathbf{x}) \\&= \sum_{\mathbf{y}_{1:t-1}} \sum_{\mathbf{y}_{t+1:n}} \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i|\mathbf{x}) \\&= \frac{1}{Z} \sum_{\mathbf{y}_{1:t-1}} \prod_{i=1}^t M_i(y_{i-1}, y_i|\mathbf{x}) \sum_{\mathbf{y}_{t+1:n}} \prod_{i=t+1}^{n+1} M_i(y_{i-1}, y_i|\mathbf{x}) \\&= \frac{1}{Z} \alpha_t(y_t|\mathbf{x}) \beta_t(y_t|\mathbf{x})\end{aligned}$$

概率计算问题

$$\begin{aligned} P(y_{t-1}, y_t | \mathbf{x}) &= \sum_{\mathbf{y}_{-\{t-1, t\}}} P(\mathbf{y} | \mathbf{x}) = \sum_{\mathbf{y}_{-\{t-1, t\}}} \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x}) \\ &= \sum_{\mathbf{y}_{1:t-2}} \sum_{\mathbf{y}_{t+1:n}} \frac{1}{Z} \prod_{i=1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x}) \\ &= \frac{1}{Z} \sum_{\mathbf{y}_{1:t-2}} \prod_{i=1}^{t-1} M_i(y_{i-1}, y_i | \mathbf{x}) \color{red}{M_t(y_{t-1}, y_t | \mathbf{x})} \sum_{\mathbf{y}_{t+1:n}} \prod_{i=t+1}^{n+1} M_i(y_{i-1}, y_i | \mathbf{x}) \\ &= \frac{1}{Z} \alpha_{t-1}(y_t | \mathbf{x}) \color{red}{M_t(y_{t-1}, y_t | \mathbf{x})} \beta_t(y_t | \mathbf{x}) \end{aligned}$$

预测问题 (Viterbi Algorithm)

- 作为习题

$$f_k(y_{i-1}, y_i, \mathbf{x}, i) = \begin{cases} t_k(y_{i-1}, y_i, \mathbf{x}, i), & k = 1, \dots, K_1 \\ s_l(y_i, \mathbf{x}, i), & l = K_1 + l; l = 1, \dots, K_2 \end{cases}$$

$$\text{记 } F_t(y_{t-1}, y_t, \mathbf{x}) = (f_1(y_{i-1}, y_i, \mathbf{x}, i), f_2(y_{i-1}, y_i, \mathbf{x}, i), \dots, f_K(y_{i-1}, y_i, \mathbf{x}, i))$$

$$K = K_1 + K_2$$

$$\mathbf{w} = (\lambda_1, \dots, \lambda_{K_1}, \mu_1, \dots, \mu_{K_2})$$

$$P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{j=1}^{K_1} \sum_{i=2}^n \lambda_j t_j(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{l=1}^{K_2} \sum_{i=1}^n \mu_l s_l(y_i, \mathbf{x}, i) \right)$$

$$\Rightarrow P(\mathbf{y}|\mathbf{x}) = \frac{1}{Z} \exp \left(\sum_{t=1}^n \mathbf{w}^\top F_t(y_{t-1}, y_t, \mathbf{x}) \right)$$

学习问题（梯度下降法）

$$f_k(y_{i-1}, y_i, \mathbf{x}, i) = \begin{cases} t_k(y_{i-1}, y_i, \mathbf{x}, i), & k = 1, \dots, K_1 \\ s_l(y_i, \mathbf{x}, i), & l = K_1 + l; l = 1, \dots, K_2 \end{cases} \quad K = K_1 + K_2$$

$$f_k(\mathbf{y}, \mathbf{x}) = \sum_{i=1}^n f_k(y_{i-1}, y_i, \mathbf{x}, i) \quad \mathbf{w} = (\lambda_1, \dots, \lambda_{K_1}, \mu_1, \dots, \mu_{K_2})$$

$$\begin{aligned} P(\mathbf{y}|\mathbf{x}, \mathbf{w}) &= \frac{1}{Z} \exp \left(\sum_{j=1}^{K_1} \sum_{i=2}^n \lambda_j t_j(y_{i-1}, y_i, \mathbf{x}, i) + \sum_{l=1}^{K_2} \sum_{i=1}^n \mu_l s_l(y_i, \mathbf{x}, i) \right) \\ &= \frac{1}{Z_w(\mathbf{x})} \exp \left(\sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) \right) \quad Z_w(\mathbf{x}) = \sum_{\mathbf{y}} \exp \left(\sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) \right) \end{aligned}$$

$$\log P(\mathbf{y}|\mathbf{x}, \mathbf{w}) = \sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) - \log Z_w(\mathbf{x})$$

学习问题（梯度下降法）

$$\text{记 } F(\mathbf{y}, \mathbf{x}) = (f_1(\mathbf{y}, \mathbf{x}), f_2(\mathbf{y}, \mathbf{x}), \dots, f_K(\mathbf{y}, \mathbf{x})) \quad f_k(\mathbf{y}, \mathbf{x}) = \sum_{i=1}^n f_k(y_{i-1}, y_i, \mathbf{x}, i)$$

$$\log P(\mathbf{y}|\mathbf{x}, \mathbf{w}) = \sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) - \log Z_{\mathbf{w}}(\mathbf{x})$$

$$\nabla_{\mathbf{w}} \log P(\mathbf{y}|\mathbf{x}, \mathbf{w}) = F(\mathbf{y}, \mathbf{x}) - \nabla_{\mathbf{w}} \log Z_{\mathbf{w}}(\mathbf{x}) = F(\mathbf{y}, \mathbf{x}) - \mathbb{E}_{\tilde{\mathbf{y}} \sim P(\tilde{\mathbf{y}}|\mathbf{x}, \mathbf{w})} F(\tilde{\mathbf{y}}, \mathbf{x})$$

$$Z_{\mathbf{w}}(\mathbf{x}) = \sum_{\mathbf{y}} \exp \left(\sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) \right)$$

$$\begin{aligned} &= \frac{1}{Z_{\mathbf{w}}(\mathbf{x})} \nabla_{\mathbf{w}} Z_{\mathbf{w}}(\mathbf{x}) \\ &= \frac{1}{Z_{\mathbf{w}}(\mathbf{x})} \sum_{\mathbf{y}} \exp \left(\sum_{k=1}^K w_k f_k(\mathbf{y}, \mathbf{x}) \right) F(\mathbf{y}, \mathbf{x}) \\ &= \sum_{\tilde{\mathbf{y}}} P(\tilde{\mathbf{y}}|\mathbf{x}, \mathbf{w}) F(\tilde{\mathbf{y}}, \mathbf{x}) = \mathbb{E}_{\tilde{\mathbf{y}} \sim P(\tilde{\mathbf{y}}|\mathbf{x}, \mathbf{w})} F(\tilde{\mathbf{y}}, \mathbf{x}) \end{aligned}$$

学习问题（梯度下降法）

Repeat

从数据集 $D = \{(\mathbf{x}_i, \mathbf{y}_i)\}$ 随机采样一个样本对

计算梯度信息 $\nabla_{\mathbf{w}} \log P(\mathbf{y}|\mathbf{x}, \mathbf{w}) = F(\mathbf{y}, \mathbf{x}) - \mathbb{E}_{\tilde{\mathbf{y}} \sim P(\tilde{\mathbf{y}}|\mathbf{x}, \mathbf{w})} F(\tilde{\mathbf{y}}, \mathbf{x})$

权重更新 $\mathbf{w}^{t+1} = \mathbf{w}^t + \nabla_{\mathbf{w}} \log P(\mathbf{y}|\mathbf{x}, \mathbf{w})$

Until 收敛

计算代价高，如何
提升计算效率呢？

主题模型

- 主题模型 (topic model) 是一类生成式**有向图模型**，主要用来处理离散型的数据集合（如文本集合）
- 有效利用海量数据发现文档集合中**隐含的语义**
- 隐狄里克雷分配模型 (Latent Dirichlet Allocation, **LDA**) 是话题模型的典型代表

隐狄里克雷分配 LDA

- LDA的基本单元

- **词 (word)** : 待处理数据中的基本离散单元
- **文档 (document)** : 待处理的数据对象, 由词组成, 词在文档中**不计顺序**。
数据对象只要能用“词袋” (bag-of-words) 表示就可以使用话题模型
- **话题 (topic)** : 表示一个概念, 具体表示为一系列相关的词, 以及它们在该概念下出现的概率

The MNIST database of **handwritten** digits, a test set of 10,000 examples. It is a su
normalized and centered in a fixed-size i

数据

计算机

生物

新闻



建筑

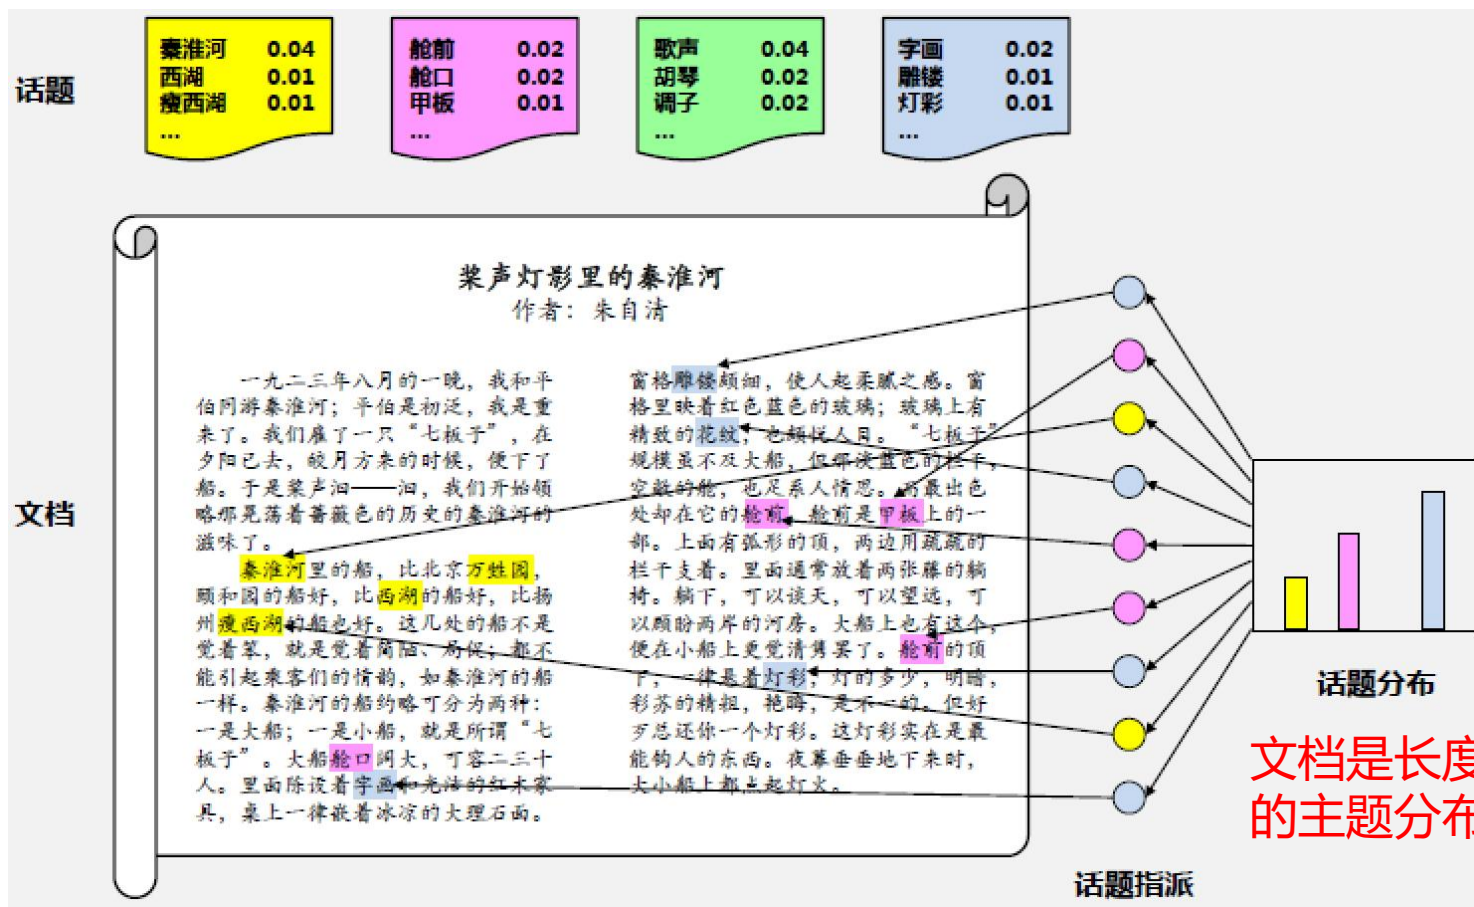
植物

天空

隐狄里克雷分配 LDA

设文档中的词来自一个包含V个词的字典


主题是V维概率词向量



隐狄里克雷分配 LDA

- 假定数据集中共含 K 个话题和 D 篇文档，词来自含 V 个词的字典
- 观测数据： D 篇文档， 每篇文档用长度为 V 的词频向量表示
 - $\mathcal{D} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$ 其中 $\mathbf{w}_d = (w_{d1}, \dots, w_{dN_d})$ 为单词序列
 - 隐变量： K 个话题 $\mathbf{z} = \{z_1, \dots, z_K\}$ ， 每个话题用长度为 N 的概率词向量表示
 - 第 k 话题 $\beta_k \in [0,1]^V$ $\beta_{kv} = P(w_v|z_k)$ 表示在第 k 个话题中单词 w_v 的概率
- 文档表示为话题的分布， 由参数 $\boldsymbol{\theta}$ 确定
 - $\boldsymbol{\theta}_t \in [0,1]^K$ $\theta_{mk} = P(z_k|\mathbf{w}_m)$

隐狄里克雷分配 LDA




生成文档 d 过程

- 从以 α 为参数的狄利克雷分布中随机采样一个话题分布 θ_d ;
- 按如下步骤产生文档中的 N_d 个词
 - 根据 θ_d 进行话题指派, 得到文档 d 中词 v 的话题 $z_{d,v}$;
 - 根据指派的话题 $z_{d,v}$ 所对应的的词分布 β_k 随机采样生成词 w_{dv}

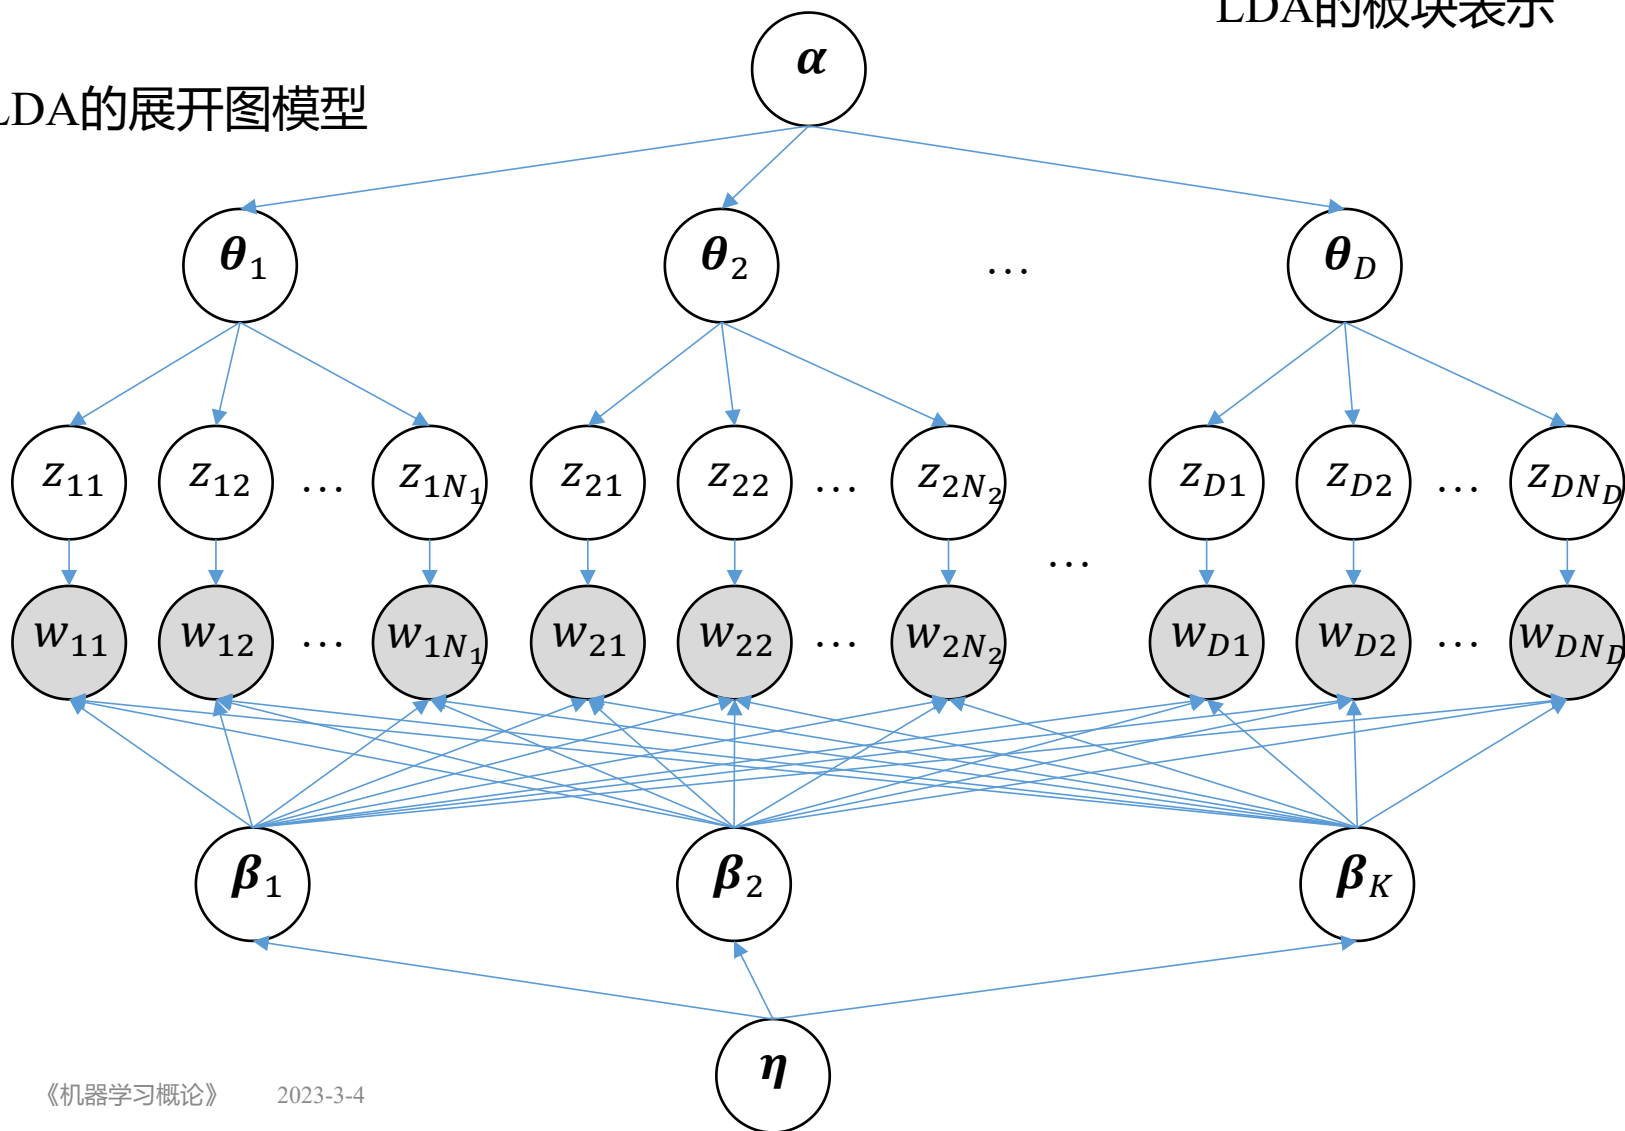
生成主题 k 过程

- 从以 η 为参数的狄利克雷分布中随机采样一个话题分布 β_k ;



LDA的板块表示

LDA的展开图模型




狄里克雷分布


$$\frac{1}{B(\alpha)}$$

$$f(\theta|\alpha) = \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \prod_{k=1}^K \theta_k^{\alpha_k-1}$$


$$\sum_k \theta_k = 1$$




$$\alpha = (1.3, 1.3, 1.3)$$




$$\alpha = (3, 3, 3)$$




$$\alpha = (7, 7, 7)$$



$$\alpha = (2, 6, 11)$$




$$\alpha = (14, 9, 5)$$



$$\alpha = (6, 2, 6)$$

隐狄里克雷分配 LDA



$$p(\mathbf{w}, \mathbf{z}, \boldsymbol{\beta}, \boldsymbol{\Theta} | \alpha, \eta) = \prod_d^D p(\boldsymbol{\theta}_d | \alpha) \prod_k^K p(\boldsymbol{\beta}_k | \eta) \left(\prod_{v=1}^{N_d} P(w_{dv} | z_{dv}, \boldsymbol{\beta}_k) P(z_{dv} | \boldsymbol{\theta}_d) \right)$$

狄里克雷分布

LDA模型的参数估计

- 给定训练数据 $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$, 参数通过极大似然法估计, 寻找 α 和 η 以最大化对数似然

$$LL(\alpha, \eta) = \sum_{d=1}^D \ln p(\mathbf{w}_d | \alpha, \eta)$$

- 求解算法
 - 可以通过吉布斯采样求解
 - 可以通过变分法求解

LDA模型的参数估计

- 给定训练数据 $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$, 参数通过极大似然法估计, 寻找 α 和 η 以最大化对数似然

$$LL(\alpha, \eta) = \sum_{d=1}^D \ln p(\mathbf{w}_d | \alpha, \eta)$$

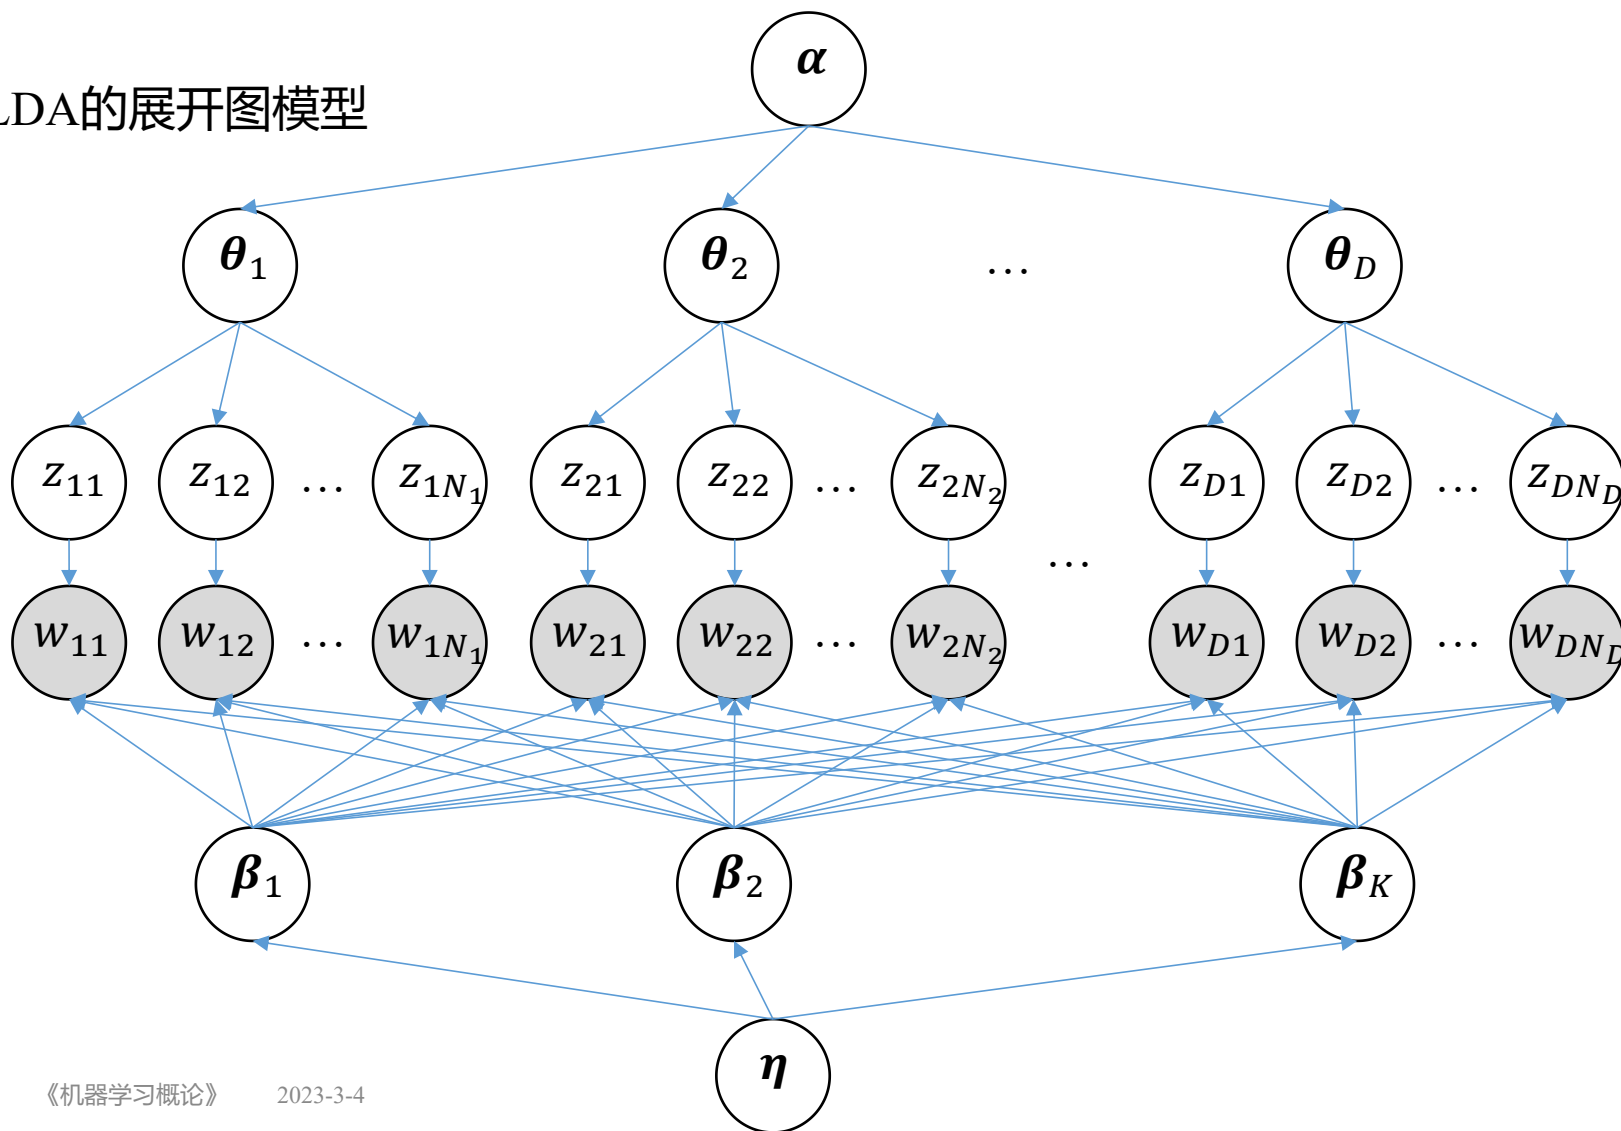
- 能否进行模型推断后用EM算法呢?

$$p(\mathbf{z}, \beta, \theta | \mathbf{w}, \alpha, \eta) = \frac{p(\mathbf{w}, \mathbf{z}, \beta, \theta | \alpha, \eta)}{p(\mathbf{w} | \alpha, \eta)}$$

模型推断的挑战

$$p(\mathbf{z}, \boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\eta}) = \frac{p(\mathbf{w}, \mathbf{z}, \boldsymbol{\beta}, \boldsymbol{\theta} | \boldsymbol{\alpha}, \boldsymbol{\eta})}{p(\mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\eta})}$$

LDA的展开图模型



LDA模型的参数估计

- 给定训练数据 $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$, 参数通过极大似然法估计, 寻找 α 和 η 以最大化对数似然

$$LL(\alpha, \eta) = \sum_{d=1}^D \ln p(\mathbf{w}_d | \alpha, \eta)$$

- 能否进行模型推断后用EM算法呢?

$$p(\mathbf{z}, \beta, \theta | \mathbf{w}, \alpha, \eta) = \frac{p(\mathbf{w}, \mathbf{z}, \beta, \theta | \alpha, \eta)}{p(\mathbf{w} | \alpha, \eta)}$$

无法进行

- 求解算法
 - 可以通过吉布斯采样求解: 通过使用随机化方法完成近似
 - 可以通过变分法求解: 使用确定性近似完成推断

近似推断：采样法

- 核心思想：用一组样本 近似 分布
- 设某个计算机程序可以产生正态分布的样本，但是参数未知。那么可以不断调用该程序，产生一组样本，从而通过样本来估计均值和方差
- 考虑计算 $\mathbb{E}_p[f(x)] = \int p(x)f(x)dx$ 或者 $\mathbb{E}_p[f(x)] = \sum_x p(x)f(x)$ ，可以通过从分布 $p(x)$ 中抽样 n 个样本 $x^{(1)}, \dots, x^{(n)}$

$$\mathbb{E}_p[f(x)] = \frac{1}{n} \sum_i f(x^{(i)})$$

关键难题：那应该如何从 $p(x)$ 从采样呢？

标准分布采样


- 伯努利分布采样: $P(x) = p^x(1 - p)^{1-x}$

$$z \sim U(0,1), \quad x = \begin{cases} 1, & z \leq p \\ 0, & \text{otherwise} \end{cases}$$

$$P(z \leq p) = p$$

标准分布采样

- 假设 z 满足均匀分布, $z \sim U(0,1)$, 通过对 z 进行变换可以求得相应分布 $p(y)$
- $p(y) = p(z) \left| \frac{dz}{dy} \right| = \left| \frac{dz}{dy} \right|$
- 左右两边积分后, 可得 $z = h(y) = \int_{-\infty}^y p(\hat{y}) d\hat{y}$
- 若 $y = h^{-1}(z)$, 那么 $y \sim p(y)$



标准分布采样

- 指数分布采样: $p(y) = \lambda \exp(-\lambda y)$
 - $h(y) = 1 - \exp(-\lambda y)$
 - $y = h^{-1}(z) = -\lambda^{-1} \ln(1 - z)$
- 标准柯西分布采样: $p(y) = \frac{1}{\pi} \frac{1}{1+y^2}$
 - $h(y) = \frac{1}{\pi} \arctan(y) + \frac{1}{2}$
 - $y = h^{-1}(z) = \tan\left(z\pi - \frac{\pi}{2}\right)$

标准分布采样

- 标准正态分布

- $z_1, z_2 \sim U(-1, 1)$

- 如果 $z_1^2 + z_2^2 > 1$, 则丢掉这对样本, 那么 $p(z_1, z_2) = \frac{1}{\pi}$

- 令 $y_1 = z_1 \left(\frac{-2 \ln z_1}{z_1^2 + z_2^2} \right)^{\frac{1}{2}}$, $y_2 = z_2 \left(\frac{-2 \ln z_2}{z_1^2 + z_2^2} \right)^{\frac{1}{2}}$, 则有

- $p(y_1, y_2) = p(z_1, z_2) \left| \frac{\partial(z_1, z_2)}{\partial(y_1, y_2)} \right| = \left[\frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} y_1^2 \right) \right] \left[\frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} y_2^2 \right) \right]$


- y_1 和 y_2 独立, 且均值为0, 方差为1

非标准分布采样

- 难以计算分布的累计概率分布并求逆函数
- 借助于两种重要而且通用的方法
 - 拒绝采样 Rejection sampling
 - 重要性重采样 Importance resampling

拒绝采样

- 从 $p(z)$ 采样很难，但是计算 $p(z)$ 很容易，可以不包括归一化项
 - $p(z) = \frac{1}{Z_p} \tilde{p}(z)$
 - $\tilde{p}(z)$ 很容易计算，但 Z_p 未知
- 提议分布 (proposal distribution): $q(z)$ ，可以轻松从中采样
- 寻找常数 k ，满足 $kq(z) \geq \tilde{p}(z)$




拒绝采样

采样过程

- 从 $q(z)$ 中采样 z_0
- 从 $U(0, kq(z_0))$ 采样 u_0
- 如果 $u_0 > \tilde{p}(z_0)$, 样本被**拒绝**, 否则被**保留**

- 图中阴影部分的样本被拒绝



拒绝采样在高维分布的问题


- $p(z)$ 是多维高斯分布, 均值为0, 协方差矩阵为 $\sigma_p I$
- $q(z)$ 是多维高斯分布, 均值为0, 协方差矩阵为 $\sigma_q I$

- 满足 $\sigma_q \geq \sigma_p$, $k^* = \left(\frac{\sigma_q}{\sigma_p}\right)^D$

- $P(\text{Accept}) = \frac{1}{k}$

维度越高, 接收概率指数级减小


在高维情况下效率极低



重要性重采样 Importance resampling

- 并不直接丢弃样本，因此采样效率提升
- 会根据提议分布和采样分布上概率的差别给每个样本加权
 - 如果采样分布 $p(z)$ 概率小，而提议分布 $q(z)$ 概率大，权重越小
 - 如果采样分布 $p(z)$ 概率大，而提议分布 $q(z)$ 概率小，权重越大
- 有一个前提条件：在 $p(z)$ 显著的地方 $q(z)$ 不能太小
- 同样难以解决从高维概率分布采样的问题

重要性重采样 Importance resampling



重要性权重，用来矫正从“错误”分布采样带来的偏差

$$\begin{aligned} E[f] &= \int f(z) p(z) dz \\ &= \int f(z) \frac{p(z)}{q(z)} q(z) dz \\ &\approx \frac{1}{L} \sum_{l=1}^L \frac{p(z^{(l)})}{q(z^{(l)})} f(z^{(l)}) \end{aligned}$$

$$\omega(z^{(l)}) = p(z^{(l)}) / q(z^{(l)})$$

Importance Sampling

- 产生样本 $z_1, \dots, z_L \sim q(z)$
- 计算

$$\hat{I} = \frac{1}{L} \sum_{l=1}^L f(z^{(l)}) \omega(z^{(l)})$$

马尔可夫链蒙特卡罗方法 (MCMC)

- 拒绝采样和重要性采样在高维情形下效率很低，通过马尔可夫链蒙特卡罗方法可以更好地扩展到高维情形
- **MCMC算法的关键在于通过“构造平稳分布为 p 的马尔可夫链”来产生样本**：当马尔可夫链运行足够长的时间（收敛到平稳状态），则产出的样本 x 近似服从 p 分布；并且通过多次重复运行、遍历马尔可夫链就可以取得多个服从该分布的独立同分布样本。
- 前提
 - 难以从 $p(z) = \tilde{p}(z)/Z_p$ 中采样，但是很容易计算 $\tilde{p}(z)$
 - 提议分布 $q(z|z^t)$ ，容易采样： z^t 为当前状态
- z_1, z_2, \dots 形成一个马尔可夫链。算法的每一轮，从提议分布中采样一个样本，按照某种规则来决定是否接受这个样本

关于MCMC的一些知识

- 一阶马尔可夫链有初始概率 $p^{(0)}(z)$ 和转移概率 $p(z'|z)$ 确定
- 在 t 时刻的状态采样概率为 $P^{(t)}(z)$, 用向量 $\boldsymbol{\pi}^{(t)}$ 来表示所有状态的概率 $P^{(t)}(z)$
- 转移概率用转移矩阵表示: $A_{i,j} = p(z' = i|z = j)$
- 马尔科夫链的动态性用如下方式表示

$$P^{(t)}(z = i) = \sum_j P^{(t-1)}(z = j)P(z' = i|z = j)$$

$$\boldsymbol{\pi}^{(t)} = \mathbf{A}\boldsymbol{\pi}^{(t-1)} = \mathbf{A}^{(t)}\boldsymbol{\pi}^{(0)}$$

关于MCMC的一些知识

- 马尔科夫链的动态性用如下方式表示

$$\boldsymbol{\pi}^{(t)} = A\boldsymbol{\pi}^{(t-1)} = A^{(t)}\boldsymbol{\pi}^{(0)}$$

- A 的每一列代表一个概率分布, A 称为随机矩阵
- 任意状态之间在可达的情况下, A 的最大特征值等于1;
- 当 $t \rightarrow \infty$ 时, 不等于1的特征值都衰减到0
- 在一些额外宽松条件下, A 只有一个特征值为1的特征向量
- MCMC会收敛到平稳分布 $\boldsymbol{\pi} = A\boldsymbol{\pi}$, 即 $\boldsymbol{\pi}$ 为对应的特征向量


关于MCMC的一些知识

- 遍历马尔可夫链有唯一的平稳分布 $p^*(z)$
 - 平稳分布满足: $p^*(z) = \sum_{z'} p(z|z')p^*(z')$
 - 遍历性 $\lim_{\tau \rightarrow \infty} p^{(\tau)}(z) = p^*(z)$, 不管初始概率分布的选择
- $p^*(z)$ 是平稳分布的充分条件: $p^*(z')p(z|z') = p(z'|z)p^*(z)$

Metropolis 算法

- 提议分布是对称的, 满足 $q(\mathbf{z}_A|\mathbf{z}_B) = q(\mathbf{z}_B|\mathbf{z}_A)$
- 从提议分布中采样的候选样本被接受的概率为

$$A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min\left(1, \frac{\tilde{p}(\mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)})}\right)$$
 - 如果 $\tilde{p}(\mathbf{z}^*) > \tilde{p}(\mathbf{z}^{(\tau)})$, 那么 \mathbf{z}^* 一定被接收
- 如果候选样本被接受, $\mathbf{z}^{(\tau+1)} = \mathbf{z}^*$, 否则 $\mathbf{z}^{(\tau+1)} = \mathbf{z}^{(\tau)}$
 - 如果 \mathbf{z}^* 被拒绝, $\mathbf{z}^{(\tau)}$ 被拷贝一次



状态 $\mathbf{z}^{(\tau)}$ 到状态 \mathbf{z}^* 的转移概率为 $q(\mathbf{z}^*|\mathbf{z}^{(\tau)})A(\mathbf{z}^*, \mathbf{z}^{(\tau)})$

只要 $q(\mathbf{z}_A|\mathbf{z}_B)$ 是正的, $\mathbf{z}^{(\tau)}$ 的分布趋近于 $p(\mathbf{z})$

Metropolis-Hastings 算法

Algorithm 24.2: Metropolis Hastings algorithm

```
1 Initialize  $x^0$  ;  
2 for  $s = 0, 1, 2, \dots$  do  
3   Define  $x = x^s$ ;  
4   Sample  $x' \sim q(x'|x)$ ;  
5   Compute acceptance probability
```

$$\alpha = \frac{\tilde{p}(x')q(x|x')}{\tilde{p}(x)q(x'|x)}$$

```
   Compute  $r = \min(1, \alpha)$ ;  
6   Sample  $u \sim U(0, 1)$  ;  
7   Set new sample to
```

$$x^{s+1} = \begin{cases} x' & \text{if } u < r \\ x^s & \text{if } u \geq r \end{cases}$$

连续变量提议分布一般选择以当前状态为均值的高斯分布，方差要做权衡

- 推广到非对称的提议分布，只需要修改接受概率

$$A(\mathbf{z}^*, \mathbf{z}^{(\tau)}) = \min \left(1, \frac{\tilde{p}(\mathbf{z}^*)q(\mathbf{z}^{(\tau)}|\mathbf{z}^*)}{\tilde{p}(\mathbf{z}^{(\tau)})q(\mathbf{z}^*|\mathbf{z}^{(\tau)})} \right)$$

状态 $\mathbf{z}^{(\tau)}$ 到状态 \mathbf{z}^* 的转移概率为
 $q(\mathbf{z}^*|\mathbf{z}^{(\tau)})A(\mathbf{z}^*, \mathbf{z}^{(\tau)})$

Metropolis-Hastings 算法

- $p(z)$ 是该算法定义的马尔科夫链的平稳分布

$$A(z^*, z^{(\tau)}) = \min \left(1, \frac{\tilde{p}(z^*)q(z^{(\tau)}|z^*)}{\tilde{p}(z^{(\tau)})q(z^*|z^{(\tau)})} \right)$$

$$\begin{aligned} p(z^{(\tau)})q(z^*|z^{(\tau)})A(z^*, z^{(\tau)}) &= \min \left(p(z^{(\tau)})q(z^*|z^{(\tau)}), p(z^*)q(z^{(\tau)}|z^*) \right) \\ &= \min \left(p(z^*)q(z^{(\tau)}|z^*), p(z^{(\tau)})q(z^*|z^{(\tau)}) \right) \\ &= p(z^*)q(z^{(\tau)}|z^*)A(z^{(\tau)}, z^*) \end{aligned}$$

Gibbs 采样

- Metropolis-Hastings 算法一个特例

状态 $\mathbf{z}^{(\tau)}$ 到状态 \mathbf{z}^* 的转移概率 $q_k(\mathbf{z}^*|\mathbf{z}^{(\tau)}) = p(z_k^*|\mathbf{z}_{-k})I(\mathbf{z}_{-k}^*=\mathbf{z}_{-k})$

1. Initialize $\{z_i : i = 1, \dots, M\}$

2. For $\tau = 1, \dots, T$:

– Sample $z_1^{(\tau+1)} \sim p(z_1|z_2^{(\tau)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$.

– Sample $z_2^{(\tau+1)} \sim p(z_2|z_1^{(\tau+1)}, z_3^{(\tau)}, \dots, z_M^{(\tau)})$.

\vdots

– Sample $z_j^{(\tau+1)} \sim p(z_j|z_1^{(\tau+1)}, \dots, z_{j-1}^{(\tau+1)}, z_{j+1}^{(\tau)}, \dots, z_M^{(\tau)})$.

\vdots

– Sample $z_M^{(\tau+1)} \sim p(z_M|z_1^{(\tau+1)}, z_2^{(\tau+1)}, \dots, z_{M-1}^{(\tau+1)})$.

可以证明：
Metropolis-Hastings步
总是被接受

Gibbs 采样

- 可以证明：Metropolis-Hastings步总是被接受

- $q_k(\mathbf{z}^*|\mathbf{z}) = p(z_k^*|\mathbf{z}_{-k})I(\mathbf{z}_{-k}^*=\mathbf{z}_{-k})$

- $p(\mathbf{z}) = p(z_k|\mathbf{z}_{-k})p(\mathbf{z}_{-k})$

- $\mathbf{z}_{-k}^*=\mathbf{z}_{-k}$

- $A(\mathbf{z}^*, \mathbf{z}) = \min \left(1, \frac{p(\mathbf{z}^*)q_k(\mathbf{z}|\mathbf{z}^*)}{p(\mathbf{z})q_k(\mathbf{z}^*|\mathbf{z})} \right)$

$$= \min \left(1, \frac{p(z_k^*|\mathbf{z}_{-k}^*)p(\mathbf{z}_{-k}^*)p(z_k|\mathbf{z}_{-k}^*)I(\mathbf{z}_{-k}^*=\mathbf{z}_{-k})}{p(z_k|\mathbf{z}_{-k})p(\mathbf{z}_{-k})p(z_k^*|\mathbf{z}_{-k})I(\mathbf{z}_{-k}^*=\mathbf{z}_{-k})} \right)$$
$$= 1$$

LDA模型的参数估计

- 给定训练数据 $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$, 参数通过极大似然法估计, 寻找 α 和 η 以最大化对数似然

$$LL(\alpha, \eta) = \sum_{d=1}^D \ln p(\mathbf{w}_d | \alpha, \eta)$$

- 能否进行模型推断后用EM算法呢?

$$p(\mathbf{z}_d, \boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{w}_d, \alpha, \eta) = \frac{p(\mathbf{w}_d, \mathbf{z}_d, \boldsymbol{\beta}, \boldsymbol{\theta} | \alpha, \eta)}{p(\mathbf{w}_d | \alpha, \eta)}$$

- 求解算法
 - 可以通过收缩的吉布斯采样求解: 通过使用随机化方法完成近似


LDA模型的参数估计—吉布斯采样

- 基本思想是通过对隐变量 θ 和 β 积分, 得到边缘概率 $P(\mathbf{z}_d|\mathbf{w}_d, \alpha, \eta)$
- 对后验概率进行吉布斯抽样, 得到分布 $P(\mathbf{z}_d|\mathbf{w}_d, \alpha, \eta)$ 的样本集合
- 利用这个样本集合对参数 α 和 η 进行参数估计

LDA模型的参数估计—吉布斯采样

- 基本思想是通过对隐变量 θ 和 β 积分，得到边缘概率 $P(\mathbf{z}|\mathbf{w}, \alpha, \eta)$

$$P(\mathbf{z}|\mathbf{w}, \alpha, \eta) = \frac{P(\mathbf{z}, \mathbf{w}|\alpha, \eta)}{P(\mathbf{w}|\alpha, \eta)}$$



$$\propto P(\mathbf{w}|\mathbf{z}, \alpha, \eta)P(\mathbf{z}|\alpha, \eta) = P(\mathbf{w}|\mathbf{z}, \eta)P(\mathbf{z}|\alpha)$$

$$P(\mathbf{w}|\mathbf{z}, \eta) = \int p(\mathbf{w}|\mathbf{z}, \beta)p(\beta|\eta)d\beta = \int \prod_{v=1}^V \prod_{k=1}^K \beta_{kv}^{n_{kv}} \prod_{k=1}^K \left(\frac{1}{B(\eta)} \prod_{v=1}^V \beta_{kv}^{\eta_v-1} \right) d\beta$$

$$\begin{aligned} p(\mathbf{w}|\mathbf{z}, \beta) &= \prod_{d=1}^D \prod_{w=1}^{N_d} \beta_{z_{dw}w} = \prod_{d=1}^D \prod_{w=1}^{N_d} \prod_{k=1}^K \beta_{kw}^{\mathbb{I}(z_{dw}=k)} \\ &= \prod_{v=1}^V \prod_{k=1}^K \beta_{kv}^{\sum_d \sum_{w=v} \mathbb{I}(z_{dw}=k)} \\ &= \prod_{v=1}^V \prod_{k=1}^K \beta_{kv}^{n_{kv}} \end{aligned}$$


数据中第k个话题生成第v个单词的次数

$$\begin{aligned} &= \prod_{k=1}^K \frac{1}{B(\eta)} \left(\int \prod_{v=1}^V \beta_{kv}^{n_{kv}+\eta_v-1} d\beta_k \right) \\ &= \prod_{k=1}^K \frac{B(\eta + \mathbf{n}_k)}{B(\eta)} \end{aligned}$$

LDA模型的参数估计—吉布斯采样

- 基本思想是通过对隐变量 θ 和 β 积分，得到边缘概率 $P(\mathbf{z}|\mathbf{w}, \alpha, \eta)$

$$P(\mathbf{z}|\mathbf{w}, \alpha, \eta) = \frac{P(\mathbf{z}, \mathbf{w}|\alpha, \eta)}{P(\mathbf{w}|\alpha, \eta)}$$



$$\propto P(\mathbf{w}|\mathbf{z}, \alpha, \eta)P(\mathbf{z}|\alpha, \eta) = P(\mathbf{w}|\mathbf{z}, \eta)P(\mathbf{z}|\alpha)$$

$$P(\mathbf{z}|\alpha) = \int p(\mathbf{z}|\boldsymbol{\theta})p(\boldsymbol{\theta}|\alpha)d\boldsymbol{\theta} = \int \prod_{d=1}^D \prod_{k=1}^K \theta_{dk}^{n_{dk}} \prod_{d=1}^D \left(\frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K \theta_{dk}^{\alpha_k - 1} \right) d\boldsymbol{\theta}$$

$$p(\mathbf{z}|\boldsymbol{\theta}) = \prod_{d=1}^D p(\mathbf{z}_d|\boldsymbol{\theta}_d) = \prod_{d=1}^D \prod_{w=1}^V \theta_{d z_{dw}}$$

$$= \prod_{d=1}^D \prod_{k=1}^K \theta_{dk}^{\sum_w \mathbb{I}(z_{dw}=k)}$$

$$= \prod_{d=1}^D \prod_{k=1}^K \theta_{dk}^{n_{dk}}$$

数据中第d个文档生成第k个单词的次数

$$= \prod_{d=1}^D \frac{1}{B(\boldsymbol{\alpha})} \left(\int \prod_{k=1}^K \theta_{dk}^{n_{dk} + \alpha_k - 1} d\boldsymbol{\theta}_d \right)$$


$$= \prod_{d=1}^D \frac{B(\boldsymbol{\alpha} + \mathbf{n}_d)}{B(\boldsymbol{\alpha})}$$

LDA模型的参数估计—吉布斯采样

- 基本思想是通过对隐变量 θ 和 β 积分, 得到边缘概率 $P(\mathbf{z}|\mathbf{w}, \alpha, \eta)$

$$\begin{aligned} P(\mathbf{z}|\mathbf{w}, \alpha, \eta) &= \frac{P(\mathbf{z}, \mathbf{w}|\alpha, \eta)}{P(\mathbf{w}|\alpha, \eta)} \\ &\propto P(\mathbf{w}|\mathbf{z}, \alpha, \eta)P(\mathbf{z}|\alpha, \eta) = P(\mathbf{w}|\mathbf{z}, \eta)P(\mathbf{z}|\alpha) \end{aligned}$$

$$P(\mathbf{w}|\mathbf{z}, \eta) = \prod_{k=1}^K \frac{B(\boldsymbol{\eta} + \mathbf{n}_k)}{B(\boldsymbol{\eta})} \quad P(\mathbf{z}|\alpha) = \prod_{d=1}^D \frac{B(\boldsymbol{\alpha} + \mathbf{n}_d)}{B(\boldsymbol{\alpha})}$$


$$P(\mathbf{z}|\mathbf{w}, \alpha, \eta) \propto \prod_{k=1}^K \frac{B(\boldsymbol{\eta} + \mathbf{n}_k)}{B(\boldsymbol{\eta})} \prod_{d=1}^D \frac{B(\boldsymbol{\alpha} + \mathbf{n}_d)}{B(\boldsymbol{\alpha})}$$

LDA模型的参数估计—吉布斯采样

即第 d' 文档中的第 w 个词

记所有文本的单词序列的第 i 个单词为 $w_i = v'$ ，对应话题为 $z_i = k'$ 的条件概率为

$$\begin{aligned}
 P(z_i = k' | \mathbf{z}_{-i}, \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\eta}) &\propto \frac{P(\mathbf{z} | \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\eta})}{P(\mathbf{z}_{-i} | \mathbf{w}, \boldsymbol{\alpha}, \boldsymbol{\eta})} = \frac{\prod_{k=1}^K \frac{B(\boldsymbol{\eta} + \mathbf{n}_k)}{B(\boldsymbol{\eta})} \prod_{d=1}^D \frac{B(\boldsymbol{\alpha} + \mathbf{n}_d)}{B(\boldsymbol{\alpha})}}{\prod_{k=1}^K \frac{B(\boldsymbol{\eta} + \mathbf{n}_k^{(-i)})}{B(\boldsymbol{\eta})} \prod_{d=1}^D \frac{B(\boldsymbol{\alpha} + \mathbf{n}_d^{(-i)})}{B(\boldsymbol{\alpha})}} \\
 &= \frac{\prod_{k=1}^K B(\boldsymbol{\eta} + \mathbf{n}_k)}{\prod_{k=1}^K B(\boldsymbol{\eta} + \mathbf{n}_k^{(-i)})} \cdot \frac{\prod_{d=1}^D B(\boldsymbol{\alpha} + \mathbf{n}_d)}{\prod_{d=1}^D B(\boldsymbol{\alpha} + \mathbf{n}_d^{(-i)})} \cdot \frac{1}{B(\boldsymbol{\alpha})} = \frac{\Gamma(\sum_{k=1}^K \alpha_k)}{\prod_{k=1}^K \Gamma(\alpha_k)} \\
 &= \frac{\frac{\prod_{k,v} \Gamma(\eta_v + n_{kv})}{\prod_k \Gamma(\sum_v \eta_v + n_{kv})}}{\frac{\Gamma(\eta_{v'} + n_{k'v'} - 1) \prod_{k \neq k', v \neq v'} \Gamma(\eta_v + n_{kv})}{\Gamma(-1 + \sum_v \eta_v + n_{k'v}) \prod_{k \neq k'} \Gamma(\sum_v \eta_v + n_{kv})}} \cdot \frac{\frac{\prod_{d,k} \Gamma(\alpha_k + n_{dk})}{\prod_d \Gamma(\sum_k \alpha_k + n_{dk})}}{\frac{\Gamma(\alpha_{k'} + n_{d'k'} - 1) \prod_{d=d', k \neq k'} \Gamma(\alpha_k + n_{dk})}{\Gamma(-1 + \sum_k \alpha_k + n_{d'k}) \prod_{d \neq d'} \Gamma(\sum_k \alpha_k + n_{dk})}} \\
 &= \frac{\frac{\Gamma(\eta_{v'} + n_{k'v'})}{\Gamma(\sum_v \eta_v + n_{k'v})}}{\frac{\Gamma(\eta_{v'} + n_{k'v'} - 1)}{\Gamma(-1 + \sum_v \eta_v + n_{k'v})}} \cdot \frac{\frac{\Gamma(\alpha_{k'} + n_{d'k'})}{\Gamma(\sum_k \alpha_k + n_{d'k})}}{\frac{\Gamma(\alpha_{k'} + n_{d'k'} - 1)}{\Gamma(-1 + \sum_k \alpha_k + n_{d'k})}} = \frac{\eta_{v'} + n_{k'v'} - 1}{-1 + \sum_v \eta_v + n_{k'v}} \cdot \frac{\alpha_{k'} + n_{d'k'} - 1}{-1 + \sum_k \alpha_k + n_{d'k}}
 \end{aligned}$$

LDA模型的参数估计—吉布斯采样

• 估计参数 θ_d


$$p(\theta_d | \mathbf{z}_d, \alpha) \propto p(\theta_d | \alpha) P(\mathbf{z}_d | \theta_d) \propto \prod_{k=1}^K \theta_{dk}^{\alpha_k - 1 + n_{dk}}$$

$$p(\theta_d | \mathbf{z}_d, \alpha) = \text{Dir}(\theta_d | \mathbf{n}_d + \alpha) \quad \Rightarrow \quad \theta_{dk} = \frac{n_{dk} + \alpha_k}{\sum_k (n_{dk} + \alpha_k)}$$

• 估计参数 β_k

$$p(\beta_k | \mathbf{w}, \eta) \propto P(\mathbf{w} | \beta_k) p(\beta_k | \eta) \propto \prod_{v=1}^V \beta_{kv}^{n_{kv} + \eta_v - 1}$$

$$p(\beta_k | \mathbf{w}, \eta) = \text{Dir}(\beta_k | \mathbf{n}_k + \eta) \quad \Rightarrow \quad \beta_{kv} = \frac{n_{kv} + \eta_v}{\sum_v (n_{kv} + \eta_v)}$$



LDA模型的参数估计

- 给定训练数据 $\mathbf{w} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_D\}$, 参数通过极大似然法估计, 寻找 α 和 η 以最大化对数似然

$$LL(\alpha, \eta) = \sum_{d=1}^D \ln p(\mathbf{w}_d | \alpha, \eta)$$

- 能否进行模型推断后用EM算法呢?

$$p(\mathbf{z}_d, \boldsymbol{\beta}, \boldsymbol{\theta} | \mathbf{w}_d, \alpha, \eta) = \frac{p(\mathbf{w}_d, \mathbf{z}_d, \boldsymbol{\beta}, \boldsymbol{\theta} | \alpha, \eta)}{p(\mathbf{w}_d | \alpha, \eta)}$$

- 求解算法
 - 可以通过收缩的吉布斯采样求解: 通过使用随机化方法完成近似
 - 可以通过变分法求解: 使用确定性近似完成推断

变分推断—EM算法回顾

$$\mathcal{L}(q, \Theta) = \sum_{\mathbf{z}} q(\mathbf{z}) \ln \frac{p(\mathbf{x}, \mathbf{z} | \Theta)}{q(\mathbf{z})}$$

$$\max_{\Theta} \ln p(\mathbf{x} | \Theta) = \max_{\Theta} \max_q \mathcal{L}(q, \Theta)$$

E

基于 Θ^t 推断隐变量 \mathbf{z} 的分布 $p(\mathbf{z} | \mathbf{x}, \Theta^t)$ ，并计算对数似然 $LL(\Theta | \mathbf{x}, \mathbf{z})$ 关于 \mathbf{z} 的期望；

$$\mathcal{L}(p(\mathbf{z} | \mathbf{x}, \Theta), \Theta) = \mathbb{E}_{\mathbf{z} \sim p(\mathbf{z} | \mathbf{x}, \Theta^t)} LL(\Theta | \mathbf{x}, \mathbf{z}) = Q(\Theta | \Theta^t)$$



M

寻找参数最大化期望似然；

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\Theta | \Theta^t)$$

变分推断—EM算法回顾

$$\max_{\Theta} \ln p(\mathbf{x}|\Theta) = \max_{\Theta} \max_q \mathcal{L}(q, \Theta)$$



EM算法的E步要求能求出最优的后验分布，若无法求解，如何是好？

答：近似后验分布

变分推断

- 平均场近似假设: $q(\mathbf{z}) = \prod_{i=1}^M q_i(\mathbf{z}_i)$ 复杂的多变量 \mathbf{z} 可以拆解为一系列相互独立的多变量 \mathbf{z}_i

- 此时最优解第 i 组随机变量的概率分布最优值为

$$q_i^*(\mathbf{z}_i) \propto \exp \mathbb{E}_{\mathbf{z}_{-i}} [\ln p(\mathbf{x}, \mathbf{z})]$$

证明

$$\begin{aligned} \mathcal{L}(q, \Theta) &= \sum_{\mathbf{z}} q(\mathbf{z}) \ln p(\mathbf{x}, \mathbf{z} | \Theta) - H(q) \\ &= \sum_{\mathbf{z}_i} q_i(\mathbf{z}_i) \sum_{\mathbf{z}_{-i}} q_{-i}(\mathbf{z}_{-i}) \ln p(\mathbf{x}, \mathbf{z} | \Theta) - \sum_{\mathbf{z}_i} q_i(\mathbf{z}_i) \ln q_i(\mathbf{z}_i) + \text{const} \\ &= \sum_{\mathbf{z}_i} q_i(\mathbf{z}_i) \mathbb{E}_{\mathbf{z}_{-i}} [\ln p(\mathbf{x}, \mathbf{z})] - \sum_{\mathbf{z}_i} q_i(\mathbf{z}_i) \ln q_i(\mathbf{z}_i) + \text{const} \end{aligned}$$

对 $q_i(\mathbf{z}_i)$ 求导数, 并令其等于0, 便可得到上述最优解

变分推断

- 平均场近似假设: $q(\mathbf{z}) = \prod_{i=1}^M q_i(\mathbf{z}_i)$ 复杂的多变量 \mathbf{z} 可以拆解为一系列相互独立的多变量 \mathbf{z}_i

- 此时最优解第 i 组随机变量的概率分布最优值为

$$q_i^*(\mathbf{z}_i) \propto \exp \mathbb{E}_{\mathbf{z}_{-i}} [\ln p(\mathbf{x}, \mathbf{z})]$$

由于在对 \mathbf{z}_i 所服从的分布 q_i^* 估计时融合了 \mathbf{z}_i 之外的其它 \mathbf{z}_{-i} 的信息, 即通过联合似然函数 $\ln p(\mathbf{x}, \mathbf{z})$ 在 \mathbf{z}_j 之外的隐变量分布上求期望得到的, 因此亦称为“平均场” (mean field) 方法

LDA模型的参数估计—变分推断

- 为简单起见, 只考虑一个文档, 记为 $\mathbf{w} = (w_1, \dots, w_N)$; 对应话题为 $\mathbf{z} = (z_1, \dots, z_N)$
- 联合概率分布 $p(\boldsymbol{\theta}, \mathbf{z}, \mathbf{w} | \boldsymbol{\alpha}, \boldsymbol{\beta}) = p(\boldsymbol{\theta} | \boldsymbol{\alpha}) \prod_{n=1}^N p(z_n | \boldsymbol{\theta}) p(w_n | z_n, \boldsymbol{\beta})$
- 平均场假设 $q(\boldsymbol{\theta}, \mathbf{z} | \boldsymbol{\gamma}, \boldsymbol{\phi}) = q(\boldsymbol{\theta} | \boldsymbol{\gamma}) \prod_{n=1}^N q(z_n | \boldsymbol{\phi}_n)$
- 证据下界
$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\phi}) = \mathbb{E}_q[\log p(\boldsymbol{\theta} | \boldsymbol{\alpha})] + \sum_{n=1}^N (\mathbb{E}_q[p(z_n | \boldsymbol{\theta})] + \mathbb{E}_q[\log p(w_n | z_n, \boldsymbol{\beta})]) \\ - \mathbb{E}_q[q(\boldsymbol{\theta} | \boldsymbol{\gamma})] - \sum_{n=1}^N \mathbb{E}_q[\log q(z_n | \boldsymbol{\phi}_n)]$$

LDA模型的参数估计—变分推断

$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\phi}) = \mathbb{E}_q[\log p(\boldsymbol{\theta}|\boldsymbol{\alpha})] + \sum_{n=1}^N (\mathbb{E}_q[p(z_n|\boldsymbol{\theta})] + \mathbb{E}_q[\log p(w_n|z_n, \boldsymbol{\eta})]) \\ - \mathbb{E}_q[q(\boldsymbol{\theta}|\boldsymbol{\gamma})] - \sum_{n=1}^N \mathbb{E}_q[\log q(z_n|\boldsymbol{\phi}_n)]$$

$$\begin{aligned} \mathbb{E}_q[\log p(\boldsymbol{\theta}|\boldsymbol{\alpha})] &= \mathbb{E}_q \left[\log \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K \theta_k^{\alpha_k-1} \right] = \mathbb{E}_q \left[\log \frac{1}{B(\boldsymbol{\alpha})} \prod_{k=1}^K \theta_k^{\alpha_k-1} \right] \\ &= \sum_k^K (\alpha_k - 1) \mathbb{E}_{q(\boldsymbol{\theta}|\boldsymbol{\gamma})}[\log \theta_k] + \log \Gamma \left(\sum_{k=1}^K \alpha_k \right) - \sum_{k=1}^K \log \Gamma(\alpha_k) \\ &= \sum_k^K (\alpha_k - 1) \left(\Psi(\gamma_k) - \Psi \left(\sum_{k=1}^K \gamma_k \right) \right) + \log \Gamma \left(\sum_{k=1}^K \alpha_k \right) - \sum_{k=1}^K \log \Gamma(\alpha_k) \end{aligned}$$

$$\Psi(\gamma_k) = \frac{d}{d\gamma_k} \Gamma(\gamma_k)$$

LDA模型的参数估计—变分推断

$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\phi}) = \mathbb{E}_q[\log p(\boldsymbol{\theta}|\boldsymbol{\alpha})] + \sum_{n=1}^N (\mathbb{E}_q[p(z_n|\boldsymbol{\theta})] + \mathbb{E}_q[\log p(w_n|z_n, \boldsymbol{\beta})]) \\ - \mathbb{E}_q[q(\boldsymbol{\theta}|\boldsymbol{\gamma})] - \sum_{n=1}^N \mathbb{E}_q[\log q(z_n|\boldsymbol{\phi}_n)]$$

$$\mathbb{E}_q[p(z_n|\boldsymbol{\theta})] = \sum_{k=1}^K \phi_{nk} \left(\Psi(\gamma_k) - \Psi\left(\sum_{k=1}^K \gamma_k\right) \right)$$

$$\mathbb{E}_q[\log p(w_n|z_n, \boldsymbol{\beta})] = \sum_{k=1}^K \sum_{v=1}^V \phi_{nk} \mathbb{I}(w_n = v) \log \beta_{kv}$$

$$\mathbb{E}_q[q(\boldsymbol{\theta}|\boldsymbol{\gamma})] = \sum_{k=1}^K (\gamma_k - 1) \left(\Psi(\gamma_k) - \Psi\left(\sum_{k=1}^K \gamma_k\right) \right) + \log \Gamma\left(\sum_{k=1}^K \gamma_k\right) - \sum_{k=1}^K \log \Gamma(\gamma_k)$$

$$\mathbb{E}_q[\log q(z_n|\boldsymbol{\phi})] = \sum_{k=1}^K \phi_{nk} \log \phi_{nk}$$

LDA模型的参数估计—变分推断

$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\phi}) = \mathbb{E}_q[\log p(\boldsymbol{\theta}|\boldsymbol{\alpha})] + \sum_{n=1}^N (\mathbb{E}_q[p(z_n|\boldsymbol{\theta})] + \mathbb{E}_q[\log p(w_n|z_n, \boldsymbol{\beta})]) \\ - \mathbb{E}_q[q(\boldsymbol{\theta}|\boldsymbol{\gamma})] - \sum_{n=1}^N \mathbb{E}_q[\log q(z_n|\boldsymbol{\phi}_n)]$$

对 ϕ_{nk} 求偏导数, 令其等于0,

$$\Psi(\gamma_k) - \Psi\left(\sum_{k=1}^K \gamma_k\right) + \sum_{v=1}^V \mathbb{I}(w_n = v) \log \beta_{kv} - 1 - \log \phi_{nk} = 0$$

➡
$$\phi_{nk} \propto \beta_{k w_n} \exp\left(\Psi(\gamma_k) - \Psi\left(\sum_{k=1}^K \gamma_k\right)\right)$$

LDA模型的参数估计—变分推断

$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta}, \boldsymbol{\gamma}, \boldsymbol{\phi}) = \mathbb{E}_q[\log p(\boldsymbol{\theta}|\boldsymbol{\alpha})] + \sum_{n=1}^N (\mathbb{E}_q[p(z_n|\boldsymbol{\theta})] + \mathbb{E}_q[\log p(w_n|z_n, \boldsymbol{\beta})]) \\ - \mathbb{E}_q[q(\boldsymbol{\theta}|\boldsymbol{\gamma})] - \sum_{n=1}^N \mathbb{E}_q[\log q(z_n|\boldsymbol{\phi}_n)]$$

$$L[\gamma_k] = \sum_{k=1}^K (\alpha_k - \gamma_k + \sum_n \phi_{nk}) \left(\Psi(\gamma_k) - \Psi(\sum_{k=1}^K \gamma_k) \right) - \log \Gamma(\sum_{k=1}^K \gamma_k) + \log \Gamma(\gamma_k)$$

对 γ_k 求偏导数, 令其等于0,

$$\frac{\partial L}{\partial \gamma_k} = (\alpha_k - \gamma_k + \sum_n \phi_{nk}) \left(\Psi'(\gamma_k) - \Psi'(\sum_{l=1}^K \gamma_l) \right) = 0$$



$$\gamma_k = \alpha_k + \sum_n \phi_{nk}$$

LDA模型的参数估计—变分推断

- 估计参数 β

- 写出全数据集上的对数似然，在等式约束下最大化似然

$$L[\boldsymbol{\beta}] = \sum_{d=1}^D \sum_{n=1}^{N_d} \sum_{k=1}^K \sum_{v=1}^V \phi_{dnk} \mathbb{I}(w_{dn} = v) \log \beta_{kv} \quad \sum_v \beta_{kv} = 1$$



$$\beta_{kv} = \sum_{d=1}^D \sum_{n=1}^{N_d} \eta_{dnk} \mathbb{I}(w_{dn} = v)$$

- 估计参数 α

$$L(\boldsymbol{\alpha}) = \sum_{d=1}^D \left(\sum_{k=1}^K (\alpha_k - 1) \left(\Psi(\gamma_{dk}) - \Psi\left(\sum_{k=1}^K \gamma_{dk}\right) \right) + \log \Gamma\left(\sum_{k=1}^K \alpha_k\right) - \sum_{k=1}^K \log \Gamma(\alpha_k) \right)$$

用梯度上升法进行优化求解

作业

• 1. *PPT 36页 详述除第一项外其余四项的化简过程

2. 假设数据集 $D = \{x_1, x_2, \dots, x_m\}$, 任意 x_i 是从均值为 μ 、方差为 λ^{-1} 的正态分布 $\mathcal{N}(\mu, \lambda^{-1})$ 中独立采样而得到。假设 μ 和 λ 的先验分布为 $p(\mu, \lambda) = \mathcal{N}(\mu|\mu_0, (\kappa_0\lambda)^{-1})\text{Gam}(\lambda|a_0, b_0)$ 其中 $\text{Gam}(\lambda|a_0, b_0) = \frac{1}{\Gamma(a_0)} b_0^{a_0} \lambda^{a_0-1} \exp(-b_0\lambda)$

(1) 请写出联合概率分布 $p(D, \mu, \lambda)$

(2) 请写出证据下界（即变分推断的优化目标），并证明其为观测数据边际似然 $\sum_{i=1}^m \log p(x_i)$ 的下界

(3) 请用变分推断法近似推断后验概率 $p(\mu, \lambda|D)$

3. PPT 46, 给出CRF的预测问题的解法